# Прикладной статистический анализ данных Последовательный анализ

Бахтеев Олег psad-2020@phystech.edu

2020

#### История задачи

#### Задача

ВМФ США хочет проверить эффективность двух типов снарядов. Производится N ( $N \approx 1000$ ) раундов обстрелов целей двумя типами снарядов, после чего производится статистический тест.

#### Проблема

Статистический тест может быть слишком расточительным. Часто знающий офицер может "на глаз" понять, какой снаряд лучше после нескольких сотен раундов.

Задача: рекламная кампания планировалась так, чтобы обеспечить узнаваемость продукта среди целевой аудитории более 30%. После окончания кампании проводится опрос с целью оценки узнаваемости.

 $H_0$ : узнаваемость продукта не превышает 30%.

 $H_1$ : узнаваемость продукта превышает 30%.

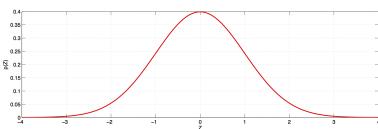
выборка:  $X^n = (X_1, \dots, X_n), X \sim Ber(p)$ 

нулевая гипотеза:  $H_0$ :  $p = p_0$ 

альтернатива:  $H_1: p > p_0$ 

статистика:  $Z(X^n) = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}}, \quad \hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$ 

нулевое распределение: N(0,1)



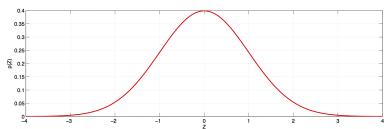
выборка:  $X^n = (X_1, \dots, X_n), X \sim Ber(p)$ 

нулевая гипотеза:  $H_0$ :  $p\leqslant p_0$ 

альтернатива:  $H_1: p > p_0$ 

статистика:  $Z(X^n) = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}}, \quad \hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$ 

нулевое распределение: N(0,1) при  $p=p_0$ 



Как выбрать наименьший достаточный объём выборки?

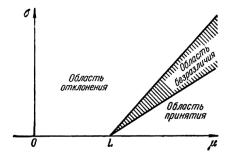
### Последовательный анализ Вальда: ключевая идея

Вместо порога  $p_0$  введем два порога:  $p_L, p_U$ . Будем полагать, что отклонение значения параметра p от  $p_0$  несущественно, если:

$$p_L \leqslant p_0 \leqslant p_U$$
.

#### Алгоритм

- $lackbox{1}$  Если  $rac{p_U}{p_L}\geqslant A$  для очередной выборки  $x_1,\ldots,x_m$ : отклонить гипотезу  $H_0.$
- $m{2}$  Если  $rac{p_U}{p_L}\leqslant B$  для очередной выборки  $x_1,\ldots,x_m$ : принять гипотезу  $H_0.$
- 3 Если  $B<rac{p_U}{p_L}< A$ , пополнить выборку: m:=m+1.



## Последовательный анализ Вальда: ключевая идея

#### Пусть:

lpha — уровень значимости — допускаемая вероятность ошибки первого рода,

eta — допускаемая вероятность ошибки второго рода.

Вероятность получения такой выборки  $x_1,\dots,x_n$ , что

$$B < rac{p_U}{p_L} < A$$
(для меньших подвыборок),  $\qquad rac{p_U}{p_L} \geqslant A$ 

при выполнении гипотезы  $H_1(p=p_U)$  больше в A раз, чем при выполнении альтернативы  $H_0(p=p_L)$ .

Но эта вероятность равна  $\alpha$  при верности  $H_0$  и  $1-\beta$  при верности  $H_1$ :

$$1 - \beta \geqslant \alpha A$$
.

#### Постановка задачи последовательного анализа

выборка: 
$$X^{m} = (X_{1}, ..., X_{m}), X \sim Ber(p).$$

Фиксируем «коридор» отклонений значения параметра p от  $p_0$ , которые можно считать несущественными:

$$p_L \leqslant p_0 \leqslant p_U$$

(хотя бы одно из неравенств — строгое).

нулевая гипотеза:  $H_0: p \leq p_L;$  альтернатива:  $H_1: p \geq p_U.$ 

Пусть данные поступают постепенно.

Задача: построить проверку гипотез так, чтобы обойтись как можно меньшим объёмом выборки.

Анонс: процедура последовательного анализа при тех же значениях мощности и уровня значимости позволяет обойтись меньшим (иногда вдвое) объёмом выборки.

#### Процедура последовательного анализа

Поскольку размер выборки не фиксирован, мы можем фиксировать вероятности ошибок обоих родов:

lpha — уровень значимости — допускаемая вероятность ошибки первого рода,

eta — допускаемая вероятность ошибки второго рода.

статистика: 
$$d_m(X^m) = \sum_{i=1}^m X_i$$
.

Введём следующие обозначения:

$$A = \frac{1 - \beta}{\alpha}, \quad B = \frac{\beta}{1 - \alpha},$$

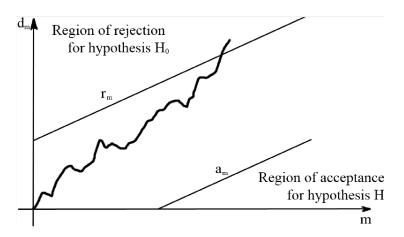
$$a_m = \frac{\ln B + m \ln \frac{1 - p_L}{1 - p_U}}{\ln \frac{p_U}{p_L} - \ln \frac{1 - p_L}{1 - p_L}},$$

$$r_m = \frac{\ln A + m \ln \frac{1 - p_L}{1 - p_U}}{\ln \frac{p_U}{p_L} - \ln \frac{1 - p_L}{1 - p_L}}.$$

#### Процедура последовательного анализа

#### При каждом значении m:

- $\bullet$   $d_m \geqslant r_m \Rightarrow$  отвергаем  $H_0, p \geqslant p_U;$
- $d_m \leqslant a_m \Rightarrow$  принимаем  $H_0, p \leqslant p_L;$
- $a_m < d_m < r_m \Rightarrow$  процесс продолжается, добавляем элемент выборки.



#### Момент остановки

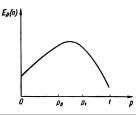
На каком элементы выборки n произойдёт остановка процедуры?

n — случайная величина, можно говорить о её матожидании:

$$\mathbb{E}_{p}(n) = \frac{L(p) \ln B + (1 - L(p)) \ln A}{p \ln \frac{p_{U}}{p_{L}} + (1 - p) \ln \frac{1 - p_{U}}{1 - p_{L}}},$$

 $L\left(p
ight)=rac{A^{h}-1}{A^{h}-B^{h}}$  — оперативная характеристика — вероятность принять нулевую гипотезу при условии, что p — истинное значение параметра; h определяется как решение уравнения:

$$p = \frac{1 - \left(\frac{1 - p_U}{1 - p_L}\right)^h}{\left(\frac{p_U}{p_L}\right)^h - \left(\frac{1 - p_U}{1 - p_L}\right)^h}.$$

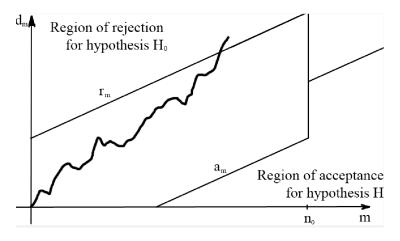


#### Усечение

Если при  $m=n_0$  решение ещё не принято, но возможности добавлять элементы выборки больше нет, используем следующий критерий:

$$\bullet$$
  $d_m\geqslant rac{a_{n_0}+r_{n_0}}{2}\Rightarrow$  отвергаем  $H_0,\ p\geqslant p_U;$ 

$$\bullet$$
  $d_m \leqslant rac{a_{n_0} + r_{n_0}}{2} \Rightarrow$  принимаем  $H_0, \ p \leqslant p_L.$ 



## Группировка наблюдений

Наблюдения могут поступать группами  $g_1,g_2,\dots$  по v элементов. Тогда значения статистики  $d_m$  сравниваются с  $a_m,r_m$  только при  $m=v,2v,\dots$ 

#### Последствия:

- увеличивается размер выборки, при котором происходит остановка;
- истинные вероятности ошибок могут оказаться больше номинальных, но при этом

$$\alpha' \leqslant \frac{\alpha}{1-\beta}, \ \beta' \leqslant \frac{\beta}{1-\alpha}.$$

Так как величины  $\alpha$  и  $\beta$  обычно малы, отклонением можно пренебречь.

## **Z**-критерий для разности двух долей, связанные выборки

выборки: 
$$X_1^n=(X_{11},\ldots,X_{1n})\,,X_1\sim Ber\,(p_1)$$
  $X_2^n=(X_{21},\ldots,X_{2n})\,,X_2\sim Ber\,(p_2)$  выборки связанные

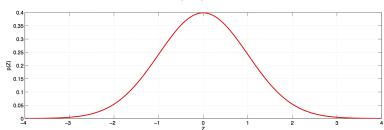
$X_1^n X_2^n$	1	0
1	e	f
0	g	h

нулевая гипотеза:  $H_0: p_1 \geqslant p_2$ 

альтернатива:  $H_1: p_1 < p_2$ 

ьтернатива:  $Z\left(X_1^n, X_2^n\right) = \frac{f-g}{\sqrt{f+g-\frac{(f-g)^2}{n}}}$ 

N(0,1) при  $p_1 = p_2$ нулевое распределение:



# Z-критерий для разности двух долей, связанные выборки

Пример: имеются два технологических процесса, классический и модернизированный,  $p_1, p_2$  — доли брака в них.

 $H_0$ : доля брака в классическом процессе не меньше доли брака в модернизированном.

 $H_1$ : доля брака в классическом процессе меньше доли брака в модернизированном.

#### Аналог в последовательном анализе

Пусть значения  $x_{1i}, x_{2i}$  поступают парами.

Будем рассматривать только различающиеся пары — (0,1) и (1,0), а остальные будем отбрасывать.

$$k_1=rac{p_1}{1-p_1},\ k_2=rac{p_2}{1-p_2}$$
 — риски,  $u=rac{k_1}{k_2}=rac{p_1(1-p_2)}{p_2(1-p_1)}$  — относительный риск:

$$\bullet \ u=1 \Leftrightarrow p_1=p_2,$$

$$u > 1 \Leftrightarrow p_1 > p_2,$$

$$\bullet$$
  $u < 1 \Leftrightarrow p_1 < p_2$ .

Фиксируем «коридор» отклонений u от 1, которые можно считать незначимыми:

$$u_L \leqslant 1 \leqslant u_U$$

(хотя бы одно из неравенств — строгое).

нулевая гипотеза:  $H_0: u \geqslant u_U$ 

альтернатива:  $H_1: u \leqslant u_L$ 

статистика:  $d_m\left(X_1^m, X_2^m\right) = \sum_{i=1}^m \left(1 - X_{1i}\right) X_{2i}$ 

#### Аналог в последовательном анализе

Константы последовательного анализа:

$$a_m = \frac{\ln B + m \ln \frac{1 - u_U}{1 - u_L}}{\ln u_U - \ln u_L},$$

$$r_m = \frac{\ln A + m \ln \frac{1 - u_U}{1 - u_L}}{\ln u_U - \ln u_L}.$$

Момент остановки:

$$\mathbb{E}_{u}(n) = \frac{L(u) \ln B + (1 - L(u)) \ln A}{\frac{u}{u+1} \ln \frac{u_{U}(1+u_{L})}{u_{L}(1+u_{U})} + \frac{1}{u+1} \ln \frac{1+u_{L}}{1+u_{U}}} / (p_{1}(1-p_{2}) + p_{2}(1-p_{1})),$$

$$L(u) = \frac{A^{h} - 1}{A^{h} - B^{h}},$$

h определяется как решение уравнения

$$\frac{u}{u+1} = \frac{1 - \left(\frac{1+u_L}{1+u_U}\right)^h}{\left(\frac{u_L(1+u_L)}{u_I(1+u_U)}\right)^h - \left(\frac{1+u_L}{1+u_U}\right)^h}.$$

## Группировка наблюдений

Наблюдения могут поступать группами  $g_1,g_2,\ldots$  пар выборок по v элементов. Если при этом внутри пар выборок не указаны соответствия элементов  $(x_{1i},x_{2i})$ , статистику  $d_m$  вычислить невозможно.

Пусть  $v_1\left(g_i\right)$  — число успехов в выборке из v наблюдений над первой биномиальной совокупностью в группе  $g_i,\,v_2(g_i)$  — над второй. Тогда для этой пары групп в качестве оценки числа пар (0,1) примем величину  $v_2(g_i)-\frac{v_1(g_i)v_2(g_i)}{v}$ .

$$d_{g_m} = \sum_{i=1}^{g_m} \left( v_2(g_i) - \frac{v_1(g_i) v_2(g_i)}{v} \right).$$

Последствия: аналогичные.

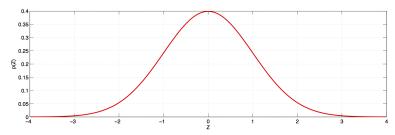
# **Z**-критерий для среднего нормального распределения, односторонняя альтернатива

выборка:  $X^n = (X_1, \dots, X_n), X \sim N(\mu, \sigma^2), \sigma$  известна

нулевая гипотеза:  $H_0: \mu \leqslant \mu_0$  альтернатива:  $H_1: \mu > \mu_0$ 

статистика:  $Z\left(X^{n}\right)=rac{ar{X}-\mu_{0}}{\sigma/\sqrt{n}}$ 

нулевое распределение: N(0,1) при  $\mu=\mu_0$ 



# **Z**-критерий для среднего нормального распределения, односторонняя альтернатива

**Пример:** при помощи прибора с известной погрешностью  $\sigma$  измеряется концентрация вредного вещества в образце. Необходимо проверить, что она не превышает предельно допустимой.

#### Аналог в последовательном анализе

Фиксируем «коридор» отклонений  $\mu$  от  $\mu_0$ , которые можно считать незначимыми:

$$\mu_L \leqslant \mu_0 \leqslant \mu_U$$

(хотя бы одно из неравенств — строгое).

нулевая гипотеза:  $H_0: \mu \leq \mu_L$ 

альтернатива:  $H_1:\mu\geqslant \mu_U$  статистика:  $d_m\left(X^m
ight)=\sum\limits_{i=1}^m X_i$ 

#### Аналог в последовательном анализе

Константы последовательного анализа:

$$a_{m} = \frac{\sigma^{2}}{\mu_{U} - \mu_{L}} \ln B + m \frac{\mu_{U} + \mu_{L}}{2},$$
$$r_{m} = \frac{\sigma^{2}}{\mu_{U} - \mu_{L}} \ln A + m \frac{\mu_{U} + \mu_{L}}{2},$$

Момент остановки:

$$\mathbb{E}_{\mu}(n) = \frac{L(\mu) \ln B (1 - L(\mu)) \ln A}{\mu_L^2 - \mu_U^2 + 2 (\mu_U - \mu_L) \mu},$$
$$L(\mu) = \frac{A^h - 1}{A^h - B^h},$$
$$h = \frac{\mu_U + \mu_L - 2\mu}{\mu_U - \mu_L}.$$

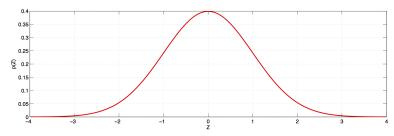
# **Z**-критерий для среднего нормального распределения, двусторонняя альтернатива

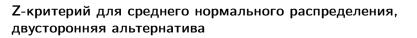
выборка:  $X^n = (X_1, \dots, X_n), X \sim N(\mu, \sigma^2), \sigma$  известна

нулевая гипотеза:  $H_0: \mu = \mu_0$  альтернатива:  $H_1: \mu \neq \mu_0$ 

статистика:  $Z(X^n) = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ 

нулевое распределение: N(0,1)





**Пример:** многократные измерения прибором с известной погрешностью для проверки наличия у прибора смещения.

#### Аналог в последовательном анализе

Фиксируем симметричный «коридор» отклонений  $\mu$  от  $\mu_0$ , которые можно считать незначимыми:

$$\left|\frac{\mu-\mu_0}{\sigma}\right| \leqslant \delta.$$

нулевая гипотеза: 
$$H_0$$
:  $\left|\frac{\mu-\mu_0}{\sigma}\right| \leqslant \delta$  альтернатива:  $H_1$ :  $\left|\frac{\mu-\mu_0}{\sigma}\right| > \delta$  статистика:  $d_m\left(X^m\right) = \ln \operatorname{ch}\left(\frac{\delta}{\sigma}\sum_{i=1}^m\left(X_i-\mu_0\right)\right)$ 

Константы последовательного анализа:

$$a_m = \ln B + m \frac{\delta^2}{2},$$

$$r_m = \ln A + m \frac{\delta^2}{2}.$$

#### Критерий хи-квадрат

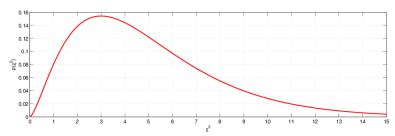
выборка:  $X^{n} = (X_{1}, \dots, X_{n}), X \sim N(\mu, \sigma^{2}), \mu$  известно

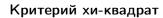
нулевая гипотеза:  $H_0: \sigma \leqslant \sigma_0$ 

альтернатива:  $H_1: \sigma > \sigma_0$ 

статистика:  $\chi^2\left(X^n\right)=rac{\sum_{i=1}^n(X_i-\mu)}{\sigma_0^2}$ 

нулевое распределение:  $\chi^2_n$  при  $\sigma=\sigma_0$ 





Пример: не превышает ли погрешность прибора заявленного уровня?

#### Аналог в последовательном анализе

Фиксируем «коридор» отклонений  $\sigma$  от  $\sigma_0$ , которые можно считать незначимыми:

$$\sigma_L \leqslant \sigma_0 \leqslant \sigma_U$$

(хотя бы одно из неравенств — строгое).

нулевая гипотеза: 
$$H_0$$
:  $\sigma \leqslant \sigma_L$ 

альтернатива: 
$$H_1 : \sigma \geqslant \sigma_U$$

статистика: 
$$d_m\left(X^m\right) = \sum\limits_{i=1}^m \left(X_i - \mu\right)^2$$

Константы последовательного анализа:

$$a_{m} = \frac{2 \ln B + m \ln \frac{\sigma_{U}^{2}}{\sigma_{L}^{2}}}{\frac{1}{\sigma_{L}^{2}} - \frac{1}{\sigma_{L}^{2}}},$$

$$r_m = \frac{2 \ln A + m \ln \frac{\sigma_U^2}{\sigma_L^2}}{\frac{1}{\sigma_L^2} - \frac{1}{\sigma_U^2}}.$$

#### Случай неизвестного среднего

Если среднее неизвестно, предлагается использовать его выборочную оценку:

статистика: 
$$d_m\left(X^m\right) = \sum\limits_{i=1}^m \left(X_i - \bar{X}\right)^2$$

При этом в последовательном анализе на m-м шаге вместо констант  $a_m, r_m$  необходимо использовать  $a_{m-1}, r_{m-1}$ .

## Доверительный интервал для среднего

Дано:  $X_1,\ldots,X_n,\ X\sim N\left(\mu,\sigma^2\right),\ \mu,\sigma$  неизвестны.

Требуется: построить доверительный интервал J для среднего  $\mu$  фиксированной длины 2d:

$$P(\mu \in J) \geqslant 1 - \alpha \ \forall \mu, \sigma.$$

При фиксированном n и неизвестном  $\sigma$  решения не существует (Данциг, 1940).

При известном  $\sigma$ :

$$J_{n} = \left[ \bar{X}_{n} - d, \bar{X}_{n} + d \right],$$

$$P\left( \mu \in J_{n} \right) = P\left( \left| \bar{X}_{n} - \mu \right| \leq d \right) = P\left( \frac{\sqrt{n} \left| \bar{X}_{n} - \mu \right|}{\sigma} \leq \frac{\sqrt{n}d}{\sigma} \right) = 2\Phi\left( \sqrt{n}d/\sigma \right) - 1;$$

$$2\Phi\left( \sqrt{n}d/\sigma \right) - 1 \geqslant 1 - \alpha = 2\Phi\left( z_{1-\alpha/2} \right) - 1;$$

так как  $\Phi$  монотонна,

$$\frac{\sqrt{nd}}{\sigma} \geqslant z_{1-\alpha/2} \Rightarrow n \geqslant \frac{z_{1-\alpha/2}^2 \sigma^2}{d^2} \equiv C.$$

C — минимальный размер выборки, при котором  $J_n$  имеет уровень доверия 1-lpha.

#### Двухэтапная процедура Стейна.

- $\P$   $X_1,\ldots,X_m$  пилотная выборка,  $m\geqslant 2, \quad S_m^2$  её выборочная дисперсия.
- ② Определим, сколько нужно добавить наблюдений:

$$\begin{split} \hat{C} &= \frac{t_{1-\alpha/2,m-1}^2 S_m^2}{d^2}, \\ N &= \max\left(\left[\hat{C}\right] + 1, m\right), \end{split}$$

 $J_N = \left[ ar{X}_N - d, ar{X}_N + d 
ight]$  — искомый 100(1-lpha)% доверительный интервал для  $\mu$ .

$$\frac{t_{1-\alpha/2,m-1}^{2}}{z_{1-\alpha/2}^{2}}C \leqslant \mathbb{E}_{\mu,\sigma}(N) \leqslant \frac{t_{1-\alpha/2,m-1}^{2}}{z_{1-\alpha/2}^{2}}C + m.$$

Двухэтапная процедура состоятельна:

$$P_{\mu,\sigma} (\mu \in J_N) \geqslant 1 - \alpha,$$

и асимптотически состоятельна:

$$\lim_{d\to 0} P_{\mu,\sigma} \left( \mu \in J_N \right) = 1 - \alpha,$$

но асимптотически неэффективна:

$$\lim_{d\to 0} \mathbb{E}_{\mu,\sigma}\left(\frac{N}{C}\right) = \frac{t_{1-\alpha/2,m-1}^2}{z_{1-\alpha/2}^2} > 1.$$

#### Полностью последовательная процедура.

- $X_1, \ldots, X_m$  пилотная выборка,  $m \geqslant 2$ .
- ullet Для каждого  $n=m,m+1,\ldots$  вычисляем

$$\hat{C}_n = \frac{z_{1-\alpha/2}^2 S_n^2}{d^2}.$$

ullet Продолжаем набирать выборку, если  $n < \hat{C}_n$ .

N — наименьшее целое  $n\geqslant \hat{C}_n$ .

$$\mathbb{E}_{\mu,\sigma}\left(N\right) \leqslant C + m.$$

Полностью последовательная процедура только асимптотически состоятельна:

$$\lim_{d\to 0} P_{\mu,\sigma} \left( \mu \in J_N \right) = 1 - \alpha,$$

но зато асимптотически эффективна:

$$\lim_{d \to 0} \mathbb{E}_{\mu, \sigma} \left( \frac{N}{C} \right) = 1.$$

## Доверительный интервал для разности двух средних

Дано:  $X_{i1}, \dots, X_{in_i}, \ X_i \sim N\left(\mu_i, \sigma_i^2\right), \ i = 1, 2.$ 

Требуется: построить доверительный интервал J для разности средних  $\mu_1 - \mu_2$  фиксированной длины 2d:

$$P(\mu_1 - \mu_2 \in J) \geqslant 1 - \alpha \ \forall \mu_1, \mu_2, \sigma_1, \sigma_2.$$

Введём следующие обозначения:

$$n = (n_1, n_2),$$

$$T_n = \bar{X}_{1n_1} - \bar{X}_{2n_2},$$

$$U_n^2 = \frac{(n_1 - 1)S_{1n_1}^2 + (n_2 - 1)S_{2n_2}^2}{n_1 + n_2 - 2}.$$

Будем рассматривать доверительные интервалы  $J_n = [T_n - d, T_n + d].$ 

### Случай $\sigma_1 = \sigma_2 = \sigma$

Поскольку дисперсии равны, будем брать выборки одинакового размера:

$$n_1 = n_2 = n,$$
  
$$U_n^2 = \frac{S_{1n}^2 + S_{2n}^2}{2}.$$

#### Двухэтапная процедура.

- lacktriangledown  $X_{i1},\ldots,X_{im}$  пилотные выборки,  $m\geqslant 2,\quad U_m^2$  оценка дисперсии по ним.
- 2 Определим, сколько нужно добавить пар наблюдений:

$$\begin{split} \hat{C} &= \frac{2t_{1-\alpha/2,2m-2}^2 U_m^2}{d^2}, \\ N &= \max\left(\left[\hat{C}\right] + 1, m\right), \end{split}$$

 $J_N = \left[ \bar{T}_N - d, \bar{T}_N + d \right]$  — искомый  $100(1-\alpha)\%$  доверительный интервал для  $\mu_1 - \mu_2.$ 

#### Случай $\sigma_1 = \sigma_2 = \sigma$

$$\frac{t_{1-\alpha/2,2m-2}^{2}}{z_{1-\alpha/2}^{2}}C \leqslant \mathbb{E}_{\mu_{1},\mu_{2},\sigma}\left(N\right) \leqslant \frac{t_{1-\alpha/2,2m-2}^{2}}{z_{1-\alpha/2}^{2}}C + m.$$

Двухэтапная процедура состоятельна и асимптотически состоятельна, но асимптотически неэффективна (по сравнению с  $C=rac{2z_{1-\alpha/2}^2\sigma^2}{d^2}$ ).

### **С**лучай $\sigma_1 \neq \sigma_2$

Пусть  $W_1, W_2 \sim St \, (m-1)$  независимы,  $h_{m,1-\alpha/2} - (1-\alpha/2)$ -квантиль распределения  $W_1 - W_2$ :

$$P(W_1 - W_2 \leqslant h_{m,1-\alpha/2}) = 1 - \frac{\alpha}{2}.$$

 $h_{m,1-\alpha/2} \approx \sqrt{2}z_{1-\alpha/2}.$ 

#### Двухэтапная процедура.

- (3)  $X_{i1},\ldots,X_{im}$  пилотные выборки,  $m\geqslant 2, \quad S_{1m}^2,S_{2m}^2$  оценки дисперсий по ним;
- ② Определим, сколько нужно добавить наблюдений в каждую выборку:

$$\begin{split} \hat{C}_1 &= \frac{h_{m,1-\alpha/2}S_{1m}^2}{d^2}, \quad \hat{C}_2 = \frac{h_{m,1-\alpha/2}S_{2m}^2}{d^2}, \\ N_1 &= \max\left(\left[\hat{C}_1\right] + 1, m\right), \quad N_2 = \max\left(\left[\hat{C}_2\right] + 1, m\right), \end{split}$$

 $J_N = \left[ \bar{T}_N - d, \bar{T}_N + d \right], \quad N = (N_1, N_2)$  — искомый  $100(1-\alpha)\%$  доверительный интервал для  $\mu_1 - \mu_2$ .

#### **С**лучай $\sigma_1 \neq \sigma_2$

$$\mathbb{E}N_i \approx \frac{h_{m,1-\alpha/2}^2 \sigma_i^2}{d^2}, \ i = 1, 2.$$

Двухэтапная процедура состоятельна.

В рамках последовательного анализа удалось найти точное решение проблемы Беренца-Фишера!

## Доверительный интервал для матожидания

Дано:  $X_1, X_2, \ldots, X \sim F(x), \mathbb{E}X, \mathbb{D}X$  конечны.

Требуется: построить доверительный интервал J для среднего  $\mathbb{E} X$  фиксированной длины 2d:

$$P(\mathbb{E}X \in J) \geqslant 1 - \alpha \ \forall F(x).$$

Если известно  $\mathbb{D}X$ , по центральной предельной теореме приближённым решением является интервал  $J_n=\left[\bar{X}_n-d,\bar{X}_n+d\right]$ , где n — наименьшее целое, удовлетворяющее условию

$$n \geqslant \frac{z_{1-\alpha/2} \left( \mathbb{D} X \right)^2}{d^2} \equiv C.$$

# Последовательные доверительные интервалы для матожидания

#### Полностью последовательная процедура.

- ullet  $X_1,\ldots,X_m$  пилотная выборка,  $m\geqslant 2, \quad S_m^2$  оценка дисперсии по ней.
- ullet Для каждого  $n=m,m+1,\ldots$  вычисляем

$$\hat{C}_n = \frac{z_{1-\alpha/2}^2 \left( S_n^2 + \frac{1}{n} \right)}{d^2}.$$

- ullet Продолжаем набирать выборку, если  $n < \hat{C}_n$ .
- $\frac{1}{n}$  поправка на случай, если распределение F(x) дискретно.

N — наименьшее целое  $n\geqslant \hat{C}_n.$ 

$$\mathbb{E}_F(N) \leqslant C + m + 2.$$

Процедура асимптотически состоятельна и асимптотически эффективна.

# Доверительный интервал для медианы

Дано: 
$$X_1, X_2, \ldots, X \sim F(x - \theta), \theta = \text{med } X,$$

- $\bullet$  F(x) симметрична относительно нуля,
- ullet  $F\left( x
  ight)$  дважды дифференцируема в окрестности нуля  $\mathcal{N}$ ;
- $\bullet$  F''(x) ограничена вне  $\mathcal{N}$ .

Требуется: построить доверительный интервал J для медианы  $\theta$  фиксированной длины 2d:

$$P(\theta \in J) \geqslant 1 - \alpha \ \forall F(x).$$

## Доверительный интервал для медианы

При фиксированом n асимптотический доверительный интервал задаётся порядковыми статистиками:

$$b(n) = \max\left(1, \left[\frac{1}{2}\left(n - z_{1-\alpha/2}\sqrt{n} - 1\right)\right]\right),$$
  

$$a(n) = n - b(n) + 1,$$
  

$$J_n = \left[X_{n:b(n)}, X_{n:a(n)}\right],$$
  

$$\lim_{n \to \infty} P\left(\theta \in J_n\right) = 1 - \alpha.$$

Чтобы построить доверительный интервал фиксированной длины 2d с помощью полностью последовательной процедуры, нужно продолжать набирать выборку, пока  $X_{n:a(n)}-X_{n:b(n)}>2d$ .

#### Литература

- последовательная проверка гипотез Вальд;
- последовательные доверительные интервалы Mukhopadhyay.

Вальд, А. Последовательный анализ, 1960.

Mukhopadhyay, N., de Silva, B. M. Sequential methods and their applications, 2009.